

PROJET :

Classification Automatique des Sons Respiratoires

*Geometry-Aware Optimization for Respiratory Sound Classification:
Enhancing Sensitivity with SAM-Optimized Audio Spectrogram Transformers*

Dataset : ICBHI 2017 Challenge

Année universitaire 2025-2026

1. Introduction

La classification automatique des sons respiratoires est un enjeu majeur pour le diagnostic précoce des maladies pulmonaires telles que l'asthme, la bronchite chronique obstructive (BPCO) ou la pneumonie. Les sons anormaux -- crackles (crépitements) et wheezes (sifflements) -- sont des indicateurs cliniques directs de pathologies pulmonaires, mais leur détection manuelle requiert une expertise spécialisée et reste sujette à la variabilité inter-observateurs.

Ce projet s'inscrit dans le cadre du challenge ICBHI 2017 (International Conference on Biomedical and Health Informatics), qui propose un dataset de 6898 cycles respiratoires annotés issus de 126 patients. L'article de référence -- Geometry-Aware Optimization for Respiratory Sound Classification (arxiv 2512.22564) -- propose un Audio Spectrogram Transformer (AST) optimisé via SAM (Sharpness-Aware Minimization) atteignant un recall macro de 68.31% et un score ICBHI de 68.10%.

L'objectif de ce projet est de **reproduire cette approche puis de la surpasser en recall (sensibilité)**, métrique prioritaire en contexte médical car les faux négatifs, une pathologie non détectée, sont cliniquement dangereux.

2. Description du Dataset ICBHI 2017

2.1 Caractéristiques générales

Le dataset ICBHI 2017 contient 6898 cycles respiratoires annotés par des experts cliniques, enregistrés dans des conditions réelles avec 4 équipements différents. La distribution des classes est très déséquilibrée :

Classe	Cycles totaux	% du total	Description
Normal	3642	52.8%	Sons respiratoires normaux
Crackle	1864	27.0%	Sons discontinus, brefs (<15ms)
Wheeze	886	12.8%	Sons continus (>80ms, ~400Hz)
Both	506	7.3%	Crackle + Wheeze simultanés

Cette distribution révèle un déséquilibre sévère : la classe Both est 7.2x moins représentée que Normal. Nos données d'entraînement (split 60/40 patient-level) confirment ce déséquilibre avec 50.7% de Normal contre seulement 7.4% de Both.

2.2 Défis spécifiques du dataset

- Bruit de fond élevé : enregistrements en conditions cliniques réelles, bruit ambiant variable
- Hétérogénéité des équipements : 4 dispositifs aux caractéristiques acoustiques différentes (AKGC417L microphone, LittC2SE, Litt3200, Meditron stethoscopes)
- Imbrication des classes : les cycles anormaux contiennent souvent de longues plages de respiration normale, le modèle tend à appliquer une 'règle de majorité' et à classer les anomalies discrètes comme Normal
- Rares échantillons purement anormaux : peu de cycles où l'anomalie domine, rendant l'apprentissage de patterns subtils difficile
- Déséquilibre sévère : Both (7.4%) vs Normal (50.7%)

2.3 Preprocessing

Chaque fichier audio .wav est converti en features acoustiques par l'ASTFeatureExtractor pré-entraîne (MIT/ast-finetuned-audioset-10-10-0.4593). Les cycles sont segmentés en fenêtres de 8 secondes à 16kHz, puis transformés en spectrogrammes mel utilisés comme entrée du modèle. Les features résultantes ont la forme (128000,) en représentation 1D avant tokenisation par l'AST.

3. Architecture du Modèle

3.1 Audio Spectrogram Transformer (AST)

L'architecture de base est un Audio Spectrogram Transformer (CustomAST) dérivé du modèle pré-entraîne sur AudioSet (MIT/ast-finetuned-audioset-10-10-0.4593). Le principe repose sur le découpage du spectrogramme en patches 2D traités comme des tokens par un encodeur Transformer, permettant de capturer les dépendances temporelles et fréquentielles à longue portée, particulièrement adaptées aux sons respiratoires qui présentent des patterns périodiques.

Le modèle est adapté à notre tâche de classification 4-classes (Normal, Crackle, Wheeze, Both) en remplaçant la tête de classification originale par un classifieur linéaire 4-classes. Les avertissements UNEXPECTED lors du chargement (classifier.dense.bias, etc.) sont normaux et attendus : ils signalent simplement que la tête AudioSet est remplacée.

3.2 SAM Optimizer (Sharpness-Aware Minimization)

Plutôt qu'un optimiseur standard (AdamW), le modèle utilise SAM (Sharpness-Aware Minimization) qui effectue une double passe à chaque itération : une première passe pour perturber les poids vers les directions de perte élevée, puis une seconde passe pour mettre à jour vers un minimum plat. Cette approche améliore la généralisation en évitant les minima aigus, particulièrement utile pour les datasets médicaux de petite taille où le risque d'overfitting est élevé.

3.3 Hyperparamètres

Paramètre	Valeur	Justification
Learning rate	1e-5	Fine-tuning de transformers pré-entraînés
Batch size	8	Contrainte mémoire GPU Kaggle
Epochs max	20	Avec early stopping patience=4-5
Optimiseur	SAM + AdamW	Approche du papier de référence
Weight decay	1e-4	Regularization L2

4. Méthodologie et Améliorations Progressives

Notre approche a consisté à partir de la reproduction du modèle original, puis à identifier systématiquement les causes de sous-performance et à appliquer des améliorations itératives. Chaque expérimentation constitue un notebook indépendant avec ses propres checkpoints, permettant une comparaison ablative rigoureuse.


4.1 Notebook 0 - Inspection du modèle de référence

Première étape : reproduire l'approche du papier sans aucune modification, pour comprendre les faiblesses du modèle de base sur notre distribution de données.


Constat principal : le modèle souffre d'un biais sévère vers la classe majoritaire (Normal). Sur le test set, Both obtient seulement 8.88% de recall contre 81.57% pour Normal. Trois problèmes identifiés :

- Déséquilibre de classes non traité : le modèle prédit Normal par défaut sur les cas ambigus
- Overfitting severe : gap Jcv - Jtrain = 0.711 (Jtrain=0.004, Jcv=0.715 a l'epoch 20)
- 442 erreurs avec confiance >80%, faux négatifs dangereux en contexte médical


NB0 - Learning Curve Analysis :




NB0 - Confusion matrices et error breakdown :



NB0 - Error Analysis :



NB0 - ROC curves and confidence :



4.2 Notebook 1 - WeightedRandomSampler + Tuning de seuils

Première amélioration : corriger le déséquilibre de classes au niveau du DataLoader via WeightedRandomSampler, et optimiser les seuils de décision sur le CV set.

WeightedRandomSampler

Principe : au lieu de tirer les batches uniformément, chaque sample est tiré avec une probabilité inversement proportionnelle à la fréquence de sa classe. La classe Both (7.4%) est ainsi surreprésentée dans chaque batch, forçant le modèle à l'apprendre. Les poids sont calculés comme :

`class_weights = 1.0 / class_counts : Normal=0.00044, Both=0.00297`

`sample_weights = class_weights[y_train]`

Tuning de seuils par descente de coordonnées


Principe : au lieu d'utiliser `argmax(probs)` pour la prédiction finale, on divise les probabilités par des seuils par classe optimisés sur le CV set. Un seuil bas (<0.5) pour Both amplifie son score relatif aux autres classes, corrigeant le biais résiduel.

`prédiction = argmax(probs / thresholds)`

L'optimisation par descente de coordonnées explore des seuils de 0.05 à 5.0 (pas initial 0.1, divise par 2 si pas d'amélioration) pour maximiser le score ICBHI sur le CV set.


Note méthodologique : ce CV set utilise un split stratifié par cycle (pas par patient), ce qui introduit un patient leakage, des cycles du même patient peuvent être en train ET en CV. Ceci explique l'écart CV ICBHI (85.28%) vs test ICBHI (65.87%), et limite l'efficacité du tuning de seuils.

NB1 - Learning curves :



NB1 - Error analysis :

ICBHI-AST-SAM — Error Analysis [Tuned thresholds]



4.3 Notebook 2 - Focal Loss (gamma=2.0)

Deuxième amélioration : remplacer la CrossEntropyLoss standard par une Focal Loss qui pondère chaque sample selon la difficulté de sa prédiction.

Formule : $L_{\text{focal}} = (1 - pt)^{\gamma} * CE(\text{logits}, \text{targets})$ avec $\gamma=2.0$

Le facteur $(1-pt)^{\gamma}$ réduit la contribution des exemples faciles (Normal prédit avec 95% de confiance) et augmente celle des exemples difficiles (Both, Wheeze). Combine au WeightedRandomSampler :




- Le sampler contrôle QUI le modèle voit (plus de minorités par batch)
- La Focal Loss contrôle COMMENT chaque sample contribue au gradient

Les poids alpha par classe (normalisés) sont passés comme paramètre à la Focal Loss pour un double rééquilibrage. L'overfitting est significativement réduit (gap 0.227 vs 0.711 précédemment), signe que la Focal Loss agit comme régulariseur.

La Focal Loss $\gamma=2.0$ dégrade Wheeze de -8.4 pts par rapport à NB1 (de 50.60% à 42.17%), ce qui justifie l'exploration de $\gamma=1.5$ en NB4.

NB2 - Learning curves :

ICBHI-AST-SAM — Learning Curve Analysis







Bias / Variance Diagnosis

Last epoch: 14
Jtrain = 0.0161
Jcv = 0.2433
Gap = 0.2272
CV Acc = 74.9%

HIGH VARIANCE
(overfitting)
→ try augmentation,
more dropout

NB2 – Error Analysis :

ICBHI-AST-SAM — Error Analysis [Tuned thresholds]



Error Summary

KEY CONFUSIONS

Normal (438 errors):
Crackle: 334, Wheeze: 79, Both: 25

Crackle (288 errors):
Normal: 264, Both: 13, Wheeze: 11

Wheeze (144 errors):
Normal: 71, Both: 53, Crackle: 20

Both (102 errors):
Wheeze: 52, Normal: 38, Crackle: 12

High-confidence (>80%) errors: 48


Both → Wheeze (83%)
Both → Wheeze (88%)
Normal → Wheeze (90%)
Normal → Wheeze (88%)
Normal → Wheeze (89%)
Normal → Wheeze (90%)

4.4 Expériment TTA (Test-Time Augmentation) - abandonne

Approche testée : appliquer N=5 passes avec perturbations légères sur chaque sample de test, puis moyenner les probabilités pour réduire la variance des prédictions.

Résultat : contre-productif (-3.91% recall, -2.34% ICBHI). Cause identifiée : les features dans notre NPZ sont stockées en 1D (shape: 128000,) le masquage fréquentiel appliqué sur un signal 1D brut est sans sens sémantique (il masque des échantillons temporels aléatoires, pas des fréquences). Les patterns diagnostiques (wheeze ~400Hz, crackles ~650Hz) sont détruits par les augmentations 1D, d'où la dégradation sévère de Wheeze (-16.1%). Approche abandonnée.

NB3 – TTA Results : dégradation de Wheeze (-16.1%)




4.5 Notebook 4 - Focal Loss (gamma=1.5) + Data Augmentation en ligne

Troisième amélioration : réduire gamma à 1.5 (le gamma=2.0 dégradait Wheeze de 9 pts en surcompensant vers Both) et ajouter une data augmentation appliquée à chaque batch **pendant l'entraînement**.


Augmentation implementée : masquage temporel, bruit gaussien, décalage temporel (roll), scaling -- avec des probabilités ciblées par classe (Normal: 20%, Crackle: 60%, Wheeze: 70%, Both: 80%).

Limitation identifiée : l'augmentation s'applique sur les features 1D brutes avant ASTFeatureExtractor. Le masquage de segments 1D n'équivaut pas à un masquage fréquentiel sur spectrogramme. De plus, l'augmentation dans `__getitem__` bloque le DataLoader (Python GIL), ralentissant l'entraînement

NB4 - Learning curves :



NB4 – Error analysis : Impact du CV leakage



4.6 Notebook 5 - Patient-level CV + Augmentation offline sur waveforms

Amélioration méthodologique majeure : corriger le patient leakage du CV split et réorganiser l'augmentation.

Correction du patient leakage

Le split précédent séparait les cycles aléatoirement, le même patient pouvait avoir des cycles en train ET en CV. Un modèle apprenant le style respiratoire d'un patient obtenait de meilleures métriques CV sans généraliser à de nouveaux patients.


Solution : split au niveau PATIENT. On assigne 30% des patients (pas des cycles) au CV set, garantissant qu'aucun patient n'est vu en train ET en CV. Ceci produit un CV plus représentatif des vraies nouvelles données, avec un écart CV/test réduit (67.23% vs 65.42%, gap de 1.8 pts contre 18-19 pts précédemment).

Augmentation offline sur waveforms bruts

Solution : pré-calculer les copies augmentées AVANT l'entraînement sur les waveforms 1D bruts (avant ASTFeatureExtractor), concaténer au dataset train, puis utiliser un ASTDataset standard. Les opérations appliquées sont time shift, bruit gaussien et scaling sémantiquement validés sur waveforms audio.


Cette approche maintient la vitesse d'entraînement de NB2 (~30 min/epoch) et augmente des signaux audio réels plutôt que des features intermédiaires.

NB5 - Learning curves :



NB5 - Error analysis : Instabilité Both (5.9%)

NB5 — Patient-level CV + Focal Loss + Augmentation offline

**5.1 Table d'ablation - Evolution du recall**

Le recall macro est la metrique principale (objectif : dépasser 68.31% du papier). Toutes les métriques sont calculees sur le test set officiel ICBHI (2358 cycles, jamais utilisé pendant l'entrainement).

Configuration	Recall macro	Specificite	ICBHI Score	Delta Recall vs NB0
NB0 AST+SAM (reproduction papier)	45.22%	83.18%	64.20%	--
NB1 + WeightedSampler + Seuils	48.30%	83.43%	65.87%	+3.08%
NB2 + Focal Loss gamma=2.0	50.28%	82.91%	66.60%	+5.06%
TTA N=5 (sur NB2)	46.38%	82.13%	64.25%	-3.90% vs NB2 (abandonne)
NB4 + Aug en ligne gamma=1.5	48.45%	82.64%	65.55%	+3.23%
NB5 + Patient CV + Aug offline	47.10%	83.16%	65.13%	+1.88%
Papier de référence (cible)	68.31%	67.89%	68.10%	--

Remarque: NB4 utilise un CV leaké (CV ICBHI affiché = 82.97% non représentatif)

Meilleur résultat obtenu : NB2 Focal Loss gamma=2.0 + WeightedSampler + Tuning de seuils avec Recall = 50.28% et ICBHI = 66.60%.

5.2 Recall par classe - Analyse detailed

Classe	NB0 (base)	NB1 (+Sampler)	NB2 (+Focal)	NB4 (+Aug)	NB5 (+PatientCV)	Papier
Normal	81.57%	73.73%	67.31%	65.40%	70.40%	68.31% (macro)
Crackle	41.83%	48.17%	52.00%	49.50%	40.20%	68.31% (macro)
Wheeze	48.59%	50.60%	42.17%	47.00%	71.90%	68.31% (macro)
Both	8.88%	20.71%	39.64%	32.00%	5.90%	68.31% (macro)

Toutes les valeurs sont post-tuning sauf NB0.

Observations clés :

- Le WeightedSampler (NB1) améliore uniformément toutes les classes minoritaires, surtout Both (+11.8 pts)
- La Focal Loss gamma=2.0 (NB2) booste fortement Both (+19 pts) mais dégrade Wheeze (-8 pts) sur-compensation
- gamma=1.5 (NB4) corrige partiellement la régression Wheeze mais reste sous NB2 en recall global
- NB5 avec patient CV révèle que les métriques précédentes étaient en partie gonflées par le leakage : Wheeze monte à 71.9% mais Both chute à 5.9%, indiquant une forte instabilité due au petit nombre de patients CV
- La Focal Loss apporte le gain le plus substantiel et le plus stable sur le recall global

5.3 Analyse des erreurs - Configuration NB2 (meilleure)

Confusions dominantes

Classe réelle	Nb erreurs	Confusion principale	Interpretation
Normal	438/1340 (32.7%)	-> Crackle (334x)	Sons normaux avec segments brefs confondus avec crackles
Crackle	288/600 (48.0%)	-> Normal	Crackles discrets noyés dans du son normal
Wheeze	144/249 (57.8%)	-> Normal	Wheezes doux confondus avec respiration normale
Both	102/169 (60.4%)	-> Wheeze	Both simplifié en Wheeze - crackle ignore

Analyse de la confiance

Le modèle NB2 présente une confiance moyenne de 61.3% sur les prédictions correctes et 58.0% sur les erreurs - écart faible de 3.3 points. Ceci contraste avec NB0 (84.7% correct vs 76.6% faux) : la Focal Loss a rendu le modèle moins sur-confiant, ce qui est positif pour la calibration des probabilités. Les erreurs à haute confiance (>80%) sont réduits de 442 (NB0) à seulement 48 (NB2) - réduction de 89%.

Analyse par device

Device	Nb samples test	Taux d'erreur NB0	Taux d'erreur NB2	Delta
AKGC417L (microphone)	1234 (52.3%)	44.9%	46.5%	+1.6%
LittC2SE (stethoscope)	143 (6.1%)	26.6%	21.7%	-4.9%
Litt3200 (stethoscope)	174 (7.4%)	38.5%	47.1%	+8.6%
Meditron (stethoscope)	807 (34.2%)	27.1%	35.3%	+8.2%

L'AKGC417L (microphone, 52% du test set) est la principale source d'erreurs. La Focal Loss améliore le recall sur LittC2SE mais dégrade sur Meditron et Litt3200, suggérant que l'augmentation de la sensibilité aux minorités se fait au détriment de la spécificité device-specific.

voir Figure NB2 – Error Analysis, section 4.3

5.4 Comparaison finale avec le papier de référence

Metrique	Notre meilleur (NB2)	Papier de reference	Gap
Recall (macro)	50.28%	68.31%	-18.03 pts
Specificite (macro)	82.91%	67.89%	+15.02 pts
ICBHI Score	66.60%	68.10%	-1.50 pts
Accuracy	58.78%	N/A	--
AUC-ROC (macro)	0.7908	N/A	--
F1-score (macro)	50.28%	N/A	--

Notre modèle surpasse le papier en spécificité (+15 pts) et est proche en ICBHI (-1.5 pts), mais reste inférieur en recall (-18 pts). Ce déséquilibre recall/spécificité est caractéristique d'un modèle encore trop conservateur dans ses prédictions de classes pathologiques.

6. Discussion

6.1 Pourquoi n'avons-nous pas atteint l'objectif de recall ?

6.1.1 Leakage de patients dans le CV split

Les notebooks NB0 à NB4 utilisent un split par cycle (stratifié), non par patient. Le modèle peut mémoriser le style respiratoire d'un patient présent en train et en CV, produisant un CV ICBHI artificiellement élevé (84-85%) non représentatif du test set réel (65-66%). Les seuils de décision optimisés sur ce CV corrompu ne transfèrent pas bien au test, d'où des gains de tuning quasi-nuls (+0.15% en NB1, +0.95% en NB2).

NB5 corrige ce problème (CV ICBHI 67.23% proche du test 65.42%, gap 1.8 pts), mais l'instabilité des résultats par classe (Wheeze 71.9% mais Both 5.9%) suggère que 22 patients CV n'est pas suffisant pour une distribution représentative de toutes les classes.

6.1.2 Gap structurel avec le papier

Le papier de référence utilise probablement des preprocessings et splits spécifiques non documentés dans le code public. En particulier, leur WeightedRandomSampler original (que nous n'avions pas dans notre reproduction initiale) et leur protocole d'évaluation précis peuvent expliquer l'écart résiduel. Notre reproduction de base (NB0) obtient ICBHI 64.20% vs 68.10% pour le papier, un écart de 3.9 pts avant toute amélioration.

6.1.3 Limitations de l'augmentation

L'augmentation sur features 1D brutes (avant ASTFeatureExtractor) n'est pas équivalente à une augmentation sur spectrogrammes 2D. Le SpecAugment standard (masquage fréquentiel sur mel-spectrogramme) serait sémantiquement plus pertinent pour les sons respiratoires et plus efficace pour la généralisation, mais nécessite de modifier src/dataset.py dans le repo.

6.2 Analyse critique de nos choix

- WeightedRandomSampler : amélioration claire et stable (+3.08% recall), jamais contre-productif. A conserver dans toute configuration future.
- Focal Loss gamma=2.0 : meilleure amélioration de recall (+5.06%), mais crée un déséquilibre entre classes. gamma=1.5 est plus stable mais moins performant globalement.
- TTA 1D : échec prévisible en rétrospective. Les features 1D ne sont pas des spectrogrammes -- le masquage aléatoire détruit des patterns diagnostiques. Approche invalide pour ce format de features.
- Patient-level CV : correction méthodologique juste, mais révèle que notre performance réelle était légèrement inférieure à ce qu'indiquaient les métriques précédentes avec leakage.

6.3 Perspectives d'amélioration

Plusieurs pistes n'ont pas pu être explorées par contrainte de temps GPU (30h/semaine sur Kaggle, ~30 min par epoch) :

- SpecAugment sur spectrogrammes 2D : modifier src/dataset.py pour appliquer le masquage fréquentiel et temporel directement sur les mel-spectrogrammes - la méthode d'augmentation la plus pertinente pour l'audio médical
- Label smoothing combiné avec Focal Loss : réduire la sur-confiance et améliorer la calibration des probabilités
- Mixup audio : interpoler linéairement deux cycles audio et leurs labels, forçant le modèle à apprendre des représentations plus lisses
- Temperature scaling : calibrer les probabilités du modèle pour améliorer l'efficacité du tuning de seuils
- Ensemble de modèles : moyenner les prédictions de plusieurs checkpoints (best ICBHI, best Wheeze recall, best Both recall) pour équilibrer les trade-offs

7. Conclusion

Ce projet a permis de reproduire et d'analyser en profondeur un modèle AST+SAM pour la classification des sons respiratoires sur ICBHI 2017. Notre analyse systématique a mis en évidence les causes de sous-performance (déséquilibre de classes, overfitting, patient leakage) et propose des améliorations itératives validées expérimentalement.

Notre meilleure configuration (NB2 : WeightedRandomSampler + Focal Loss gamma=2.0 + Tuning de seuils) atteint un recall macro de 50.28% et un ICBHI de 66.60%, représentant une amélioration de +5.06 pts de recall par rapport à notre reproduction de base. Bien que l'objectif de dépasser le papier (68.31% recall) n'ait pas été atteint, plusieurs contributions méthodologiques importantes émergent de ce travail :

- Démonstration que la Focal Loss est supérieure à la CrossEntropyLoss pour les datasets médicaux déséquilibrés, même avec WeightedRandomSampler actif
- Identification et correction du patient leakage dans le CV split, avec quantification de son impact (+18 pts d'ecart CV/test)
- Preuve que le TTA est contre-productif sur des features 1D pré-calculées et doit être réservé aux représentations 2D
- Table d'ablation complète permettant de quantifier la contribution indépendante de chaque amélioration

Ces résultats constituent une base solide pour de futures améliorations, notamment l'implémentation du SpecAugment 2D qui représente la piste la plus prometteuse pour franchir le seuil de recall du papier de référence.